Introdução à Análise de Dados de Contagem com R

Eduardo E. R. Junior

Curso de Estatística - UFPR
MEETUP USER-SP

08 de abril de 2016

edujrrib@gmail.com

Introdução à Análise de Dados de Contagem com R

Eduardo E. R. Junior

Curso de Estatística - UFPR
MEETUP USER-SP

08 de abril de 2016

edujrrib@gmail.com

Disponibilização

https://github.com/jreduardo/meetup-iadcr

Introdução à Análise de Dados de Contagem com R - meetup-iadcr

Sumário

1. Introdução
2. Modelo Poisson
3. Modelos Alternativos

1

Introdução

Representam o número de ocorrências de um evento de interesse em um domínio específico.
Se Y é uma v.a de contagem, $y \in \mathbb{Z}_+$, ou seja, $y = 0, 1, 2, ...$

Exemplos:

- Número de filhos por casal;
- Número de indivíduos infectados por uma doença;
- Número de insetos mortos após k dias da aplicação de inseticida;
- …

2

Modelo Poisson

Distribuição Poisson

Densidade de probabilidade

$$\Pr(Y = y \mid \lambda) = \frac{\lambda^y}{y! e^\lambda}, \quad y \in \mathbb{Z}_+ \tag{1}$$

Propriedades

- $\frac{P(Y=y-1)}{P(Y=y)} = \frac{y}{\lambda}$
- $E(Y) = \lambda$
- $V(Y) = \lambda$

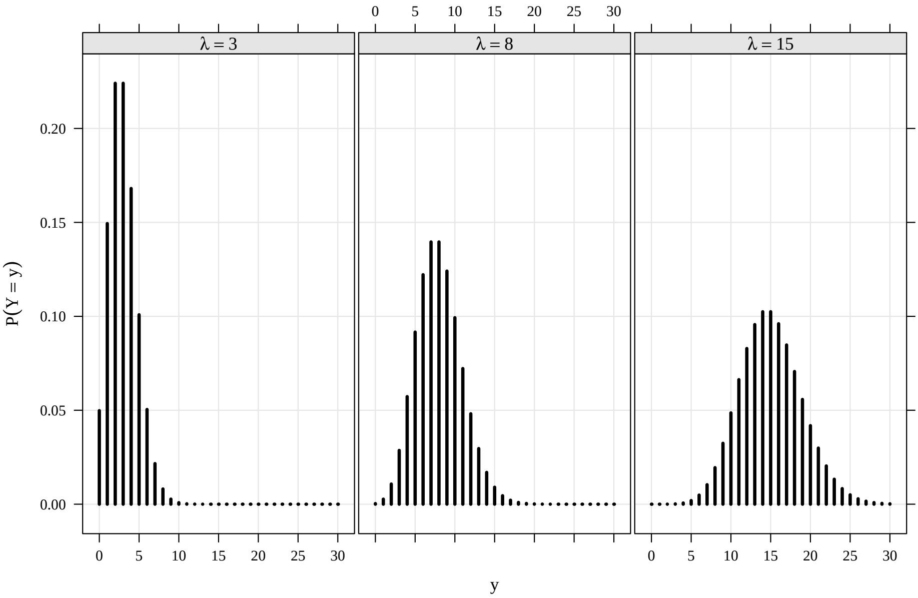

Figure 1: Probabilidades para modelos Poisson

Regressão Poisson

$$
\begin{aligned}
Y_i \mid X_i, t_i &\sim \text{Poisson}(\mu_i = \lambda_i t_i) \\
g(\lambda_i t_i) &= \eta_i = X_i \beta
\end{aligned}
$$

Sendo g uma função monótona que,

- Linearize a relação entre μ e η; e
- Confira valores válidos para μ (pertencente ao espaço paramétrico)

As duas funções de ligação mais comuns são $\log \mu$ e $\sqrt{\mu}$

Modelo log-linear Poisson

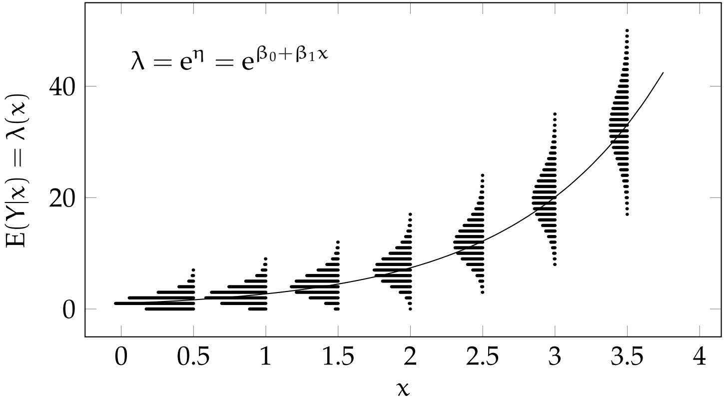

Figure 2: Representação esquemática de um modelo de regressão Poisson

Estimação

- Via maximização da log-Verossimimilhança
  $ll(\beta \mid X) = yX\beta - X\beta - \log(X!)$

- Via Mínimos Quadrados Ponderados Iterativamente
  Utiliza as propriedades da família exponencial
  $\beta^{m+1} = (X^t W^m X)^{-1} X^t W^m z^m$

- No R

```
model <- glm(y ~ preditor, family = poisson)
```

Estudos de caso

- `anomalias.html` - Caso equidisperso

3

Modelos Alternativos

3.1

Modelos Alternativos

Fuga de equidispersão

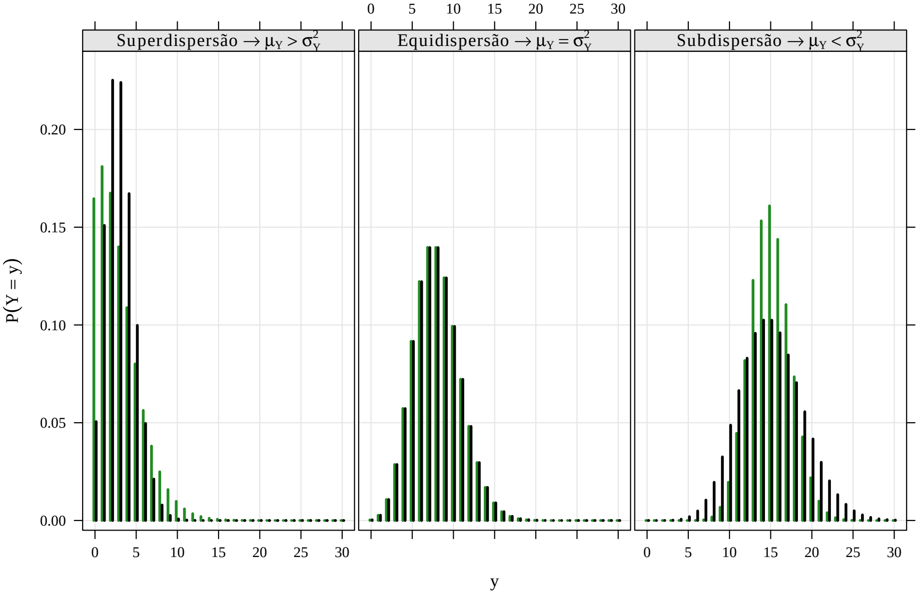

Figure 3: Probabilidades para a não verificação de equidispersão

Modelo Binomial Negativo

Também chamado de Modelo de mistura *gamma-Poisson* (BN)

$$Y \sim \text{Poisson}(\lambda)$$
$$\lambda \sim \text{Gamma}(\mu, k = \phi\mu)$$

- Distribuição marginal Binomial Negativa $(\pi = 1/(1+\phi),\ k)$
- Acomoda somente superdispersão
- Função de ligação canônica problemática No R

```
## Support Functions and Datasets for Venables and Ripley's MASS
library(MASS)
model <- glm.nb(y ~ preditor)
```

Modelos de Quasi-Verossimilhança

- Estimação baseada em momentos
  $E(Y|X) = \exp X\beta$
  $V(Y|X) = \phi \exp X\beta$
- Interpretação de ϕ
  $0 < \phi < 1 \rightarrow$ subdisperso
  $\phi = 1 \rightarrow$ equidisperso
  $\phi > 1 \rightarrow$ superdisperso
- Estimação de ϕ
  $\hat{\phi} = \sum r_{pad}^2/(n-p)$
- No R

```r
model <- glm(y ~ preditor, family = quasipoisson)
```

Estudos de caso

- `ninfas.html` - Caso superdisperso
- `capulhos.html` - Caso subdisperso

Outras abordagens

3.2

Modelos Alternativos

Excesso de zeros

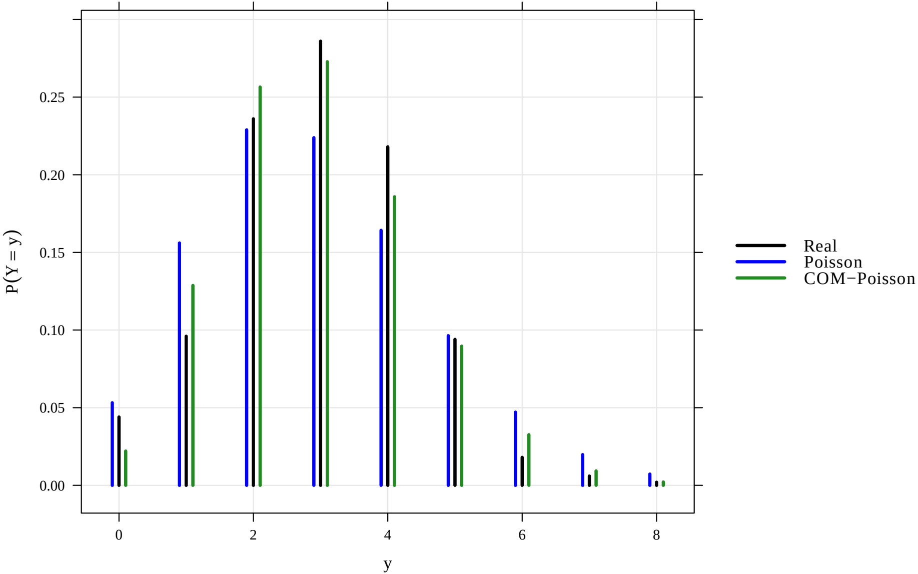

Figure 4: Contagens que apresentam excesso de zeros

Modelos de Barreia *Hurdle models*

São chamados também de modelos condicionais ou truncados

$$\Pr(Y = y) = \begin{cases} \pi & \text{se } \; y = 0, \\ (1 - \pi) \dfrac{P_Y(y)}{1 - P_Y(0)} & \text{se } \; y = 1, 2, \dots \end{cases} \tag{2}$$

Sendo P_Y uma distribuição de probabilidades associada às contagens e π a probabilidade associada às contagens 0.

```
## Political Science Computational Laboratory, Stanford University
library(pscl)

hurdle(resp ~ py_preditor | pi_preditor, dist = "poisson")
```

Modelos de Inflação *Zero Inflated Models*

São chamados também de modelos de mistura

$$\Pr(Y = y) = \begin{cases} \pi + (1 - \pi)P_Y(0) & \text{se } y = 0, \\ (1 - \pi)P_Y(y) & \text{se } y = 1, 2, \dots \end{cases} \tag{3}$$

Sendo P_Y uma distribuição de probabilidades associada às contagens e π a probabilidade associada às contagens 0.

```
## Political Science Computational Laboratory, Stanford University
library(pscl)

zeroinfl(resp ~ py_preditor | pi_preditor, dist = "poisson")
```

3.3

Modelos Alternativos
Outras abordagens

COM-Poisson

Densidade de probabilidade

$$\Pr(Y = y \mid \lambda, \nu) = \frac{\lambda^y}{(y!)^\nu Z(\lambda, \nu)}, \quad y \in \mathbb{Z}_+ \tag{4}$$

onde $Z(\lambda, \nu) = \sum_{j=0}^{\infty} \frac{\lambda^j}{(j!)^\nu}$; e $\qquad \lambda > 0$ e $\nu \geqslant 0$

Propriedades

- $\frac{P(Y=y-1)}{P(Y=y)} = \frac{y^\nu}{\lambda}$
- $E(Y^\nu) = \lambda$

Casos particulares

- Distribuição Poisson, quando $\nu = 1$
- Distribuição Bernoulli, quando $\nu \to \infty$
- Distribuição Geométrica, quando $\nu = 0, \ \lambda < 1$

Modelo *Gamma-Count*

Densidade de probabilidade

$$\Pr(Y = y \mid \alpha, \beta) = G(y, n\alpha, \beta T) - G(y, n\alpha + \alpha, \beta T), \quad y \in \mathbb{Z}_+ \tag{5}$$

onde $G(y, \theta_1, \theta_2)$ é a distribuição de densidade acumulada até o ponto y da Gamma de parâmetros θ_1 e θ_2; e $\alpha > 0$ e $\beta > 0$

Propriedades

- Generaliza a relação entre Poisson e Exponencial, considerando que o tempo entre eventos agora pode ser um Gamma com parâmetros estimados.

Casos particulares

- Distribuição Poisson, quando $\alpha = 1$

Efeitos Aleatórios

$$
\begin{aligned}
Y \mid b \sim & f_*(\mu, \phi) \\
g(\mu) = & \beta_0 + b_i \\
b_i \sim & D(\Sigma)
\end{aligned}
$$

$$\Pr(Y = y) = \int_{D_D} [Y \mid X, b_i][b_i] db_i \tag{6}$$

Onde D é a distribuição associada aos efeitos aleatórios e D_D é o suporte da distribuição.

- Necessários, métodos de integração numérica
  - Aproximação de Laplace
  - Quadratura Gaussiana
  - Monte Carlo (e.g. MCMC)

Entre outros

- Modelos para dados censurados
- Modelos para respostas correlacionadas
- …

Participe!

Minicurso: Modelos de Regressão para Dados de Contagem com R - `MRDCr`
Autores: Walmes M. Zeviani, Eduardo E. R. Junior, Cesar A. Taconelli

Obrigado!